

WSI 생존예측을 위한 MIL 집계 기법 분석

김유진¹, 김성흠²

¹ 숭실대학교 AI 소프트웨어학부 학부생

² 숭실대학교 AI 소프트웨어학부 교수

yujin16@soongsil.ac.kr, seongheum@ssu.ac.kr

A Study of MIL Aggregation Methods for WSI-based Survival Prediction

Yu-Jin Kim, Seong-heum Kim*

School of AI Software, Soongsil University

요 약

디지털 병리 분야에서는 병리 이미지(Whole Slide Image, WSI) 기반 생존예측을 위해 다양한 다중 인스턴스 학습(Multiple Instance Learning, MIL) 집계 기법이 제안되고 있다. 이들은 단순 평균 집계에서 출발하여, 인스턴스의 중요도를 학습하는 어텐션(attention) 기반 기법과 인스턴스 간 상관관계를 모델링하는 트랜스포머(Transformer) 및 상태공간모델(State Space Model) 기반 기법으로 점차 복잡해지는 방향으로 발전해 왔다. 그러나 이러한 복잡한 집계 구조는 높은 계산 비용과 구현 복잡성을 수반하며, 강력한 사전학습 특징 추출기가 널리 활용되는 최근 환경에서도 그 복잡성이 여전히 유효한지는 충분히 검증되지 않았다. 이에 본 연구는 동일한 특징 추출 환경에서 Mean Pooling, ABMIL, TransMIL, MambaMIL 을 비교하여 집계 구조의 복잡성과 생존예측 성능 간의 관계를 분석하였다. 실험 결과 집계 기법에 따라 성능 차이가 나타났으며, 상대적으로 단순한 ABMIL 이 가장 높은 C-index 를 기록하였다. 이는 강력한 사전학습 특징을 사용하는 경우 집계 구조의 복잡성 증가가 반드시 성능 향상으로 이어지지 않음을 시사한다.

1. 서론

병리 이미지(Whole Slide Image, WSI)는 조직 슬라이드를 초고해상도로 디지털화한 영상으로, 세포 구조와 종양 미세환경 등의 정보를 담고 있어 암 진단과 예후 예측 등 다양한 의료 분야에 활용된다. 디지털 병리의 발전과 함께 WSI 기반 인공지능 연구가 지속되어 왔으며, 파운데이션 모델의 도입으로 표현력이 크게 향상되었다[1]. 이러한 표현 학습의 발전은 특히 환자의 생존 기간 및 예후를 예측하는 생존분석에서 두드러지며 환자 별 치료 전략과 추적 관찰 계획 수립에 중요한 근거를 제공한다[2].

WSI는 패치 단위로 특징을 추출한 후 통합하는 다중 인스턴스 학습(Multiple Instance Learning, MIL) 기반 접근법이 널리 사용된다[3]. 이러한 MIL 집계 기법은 패치 간 중요도와 상호작용을 모델링하는 방향으로 점차 복잡해지고 있다[4-7].


기존 연구는 주로 복잡한 MIL 구조의 개발에 집중해 왔으나, 파운데이션 모델로 고품질 특징을 확보할

수 있는 환경에서도 복잡한 집계 구조가 반드시 필요한지는 충분히 검증되지 않았다. 따라서 본 연구에서는 네 가지의 MIL 집계 기법의 생존예측 성능을 비교하여, 강력한 사전학습 특징 환경에서 집계 구조의 복잡성이 성능 향상에 기여하는지를 검토한다.

2. 관련 연구

MIL은 인스턴스의 레이블 없이 bag의 레이블만을 이용하는 약지도 학습이다. WSI 분석에서는 다수의 패치(인스턴스)를 슬라이드 또는 환자 수준의 표현(bag)으로 집계하는 함수가 모델 성능을 결정하는 핵심 요소이다. 집계 방식의 선택은 패치 간 관계를 어떻게 표현할지를 결정하며, 하위 태스크의 성능에 직접적인 영향을 미친다. 기본적인 방식인 Mean Pooling은 패치 간 중요도 차이와 상호작용을 고려하지 못한다. MIL 집계 기법들은 이러한 한계를 보완하고자 발전해 왔다.

Ilse et al. [4]은 각 패치의 중요도를 학습하여 가중합



(그림 1) WSI 기반 계층적 MIL 집계 및 생존예측 파이프라인.

하는 ABMIL을 제안하였다. ABMIL은 각 패치 특징으로부터 독립적으로 어텐션 가중치를 산출하여 슬라이드 수준 표현을 생성한다. 따라서 Transformer의 self-attention과 달리 패치 간 상호작용을 직접 모델링하지 않으며, 계산 복잡도는 $O(N)$ 으로 낮게 유지된다. 본 연구에서는 Lu et al. [5]의 CLAM에서 군집화 손실을 제외한 Gated Attention Pooling 모듈을 집계기로 활용하였다.

Shao et al. [6]은 self-attention으로 패치 간 상관관계를 표현할 수 있는 TransMIL을 제안하였다. 표준 self-attention의 $O(N^2)$ 복잡도는 수만 개의 패치로 구성된 WSI에 적용하기 어려우므로, 이를 Nyström 근사를 통해 선형 복잡도로 완화하였다. 그리고 패치의 2차원 공간 위치 정보를 함께 인코딩하여 공간적 상관관계를 포착했다.

Yang et al. [7]은 TransMIL과 동일하게 패치 간 상관관계를 모델링할 수 있는 선택적 상태공간모델(Selective State Space Model, SSM) 기반의 MambaMIL을 제안하였다. SSM은 패치 시퀀스를 순차적으로 처리하여 장거리 의존성을 $O(N)$ 복잡도로 모델링한다. 그러나 이러한 순차적 처리 방식은 입력 순서에 따라 결과가 변형되는 한계가 존재한다. 이에 MambaMIL은 패치를 공간 좌표 기반으로 재배열하여 지역적 연속성을 확보하는 순서화 전략을 통해 해결하였다.

각 집계 기법을 적용한 모델의 파라미터 수는 Mean Pooling 0.79M, ABMIL 1.05M, TransMIL 2.94M, MambaMIL 4.75M로, 인스턴스 간 상호작용을 모델링하는 TransMIL과 MambaMIL이 더 많은 파라미터를 필요로 한다.

3. 구현 및 분석 방법

본 연구의 파이프라인은 UNI 기반 특징 추출, 계층적 MIL 집계 및 Cox 회귀 기반 생존 예측으로 구성된다. 성능 비교를 위해 특징 추출기와 후속 구조는 고정하고 1단계 집계 기법만을 교체하여 실험을 진행

하였다. 패치 수준의 특징 추출에는 대규모 병리 영상 데이터로 사전 학습된 파운데이션 모델인 UNI[1]를 활용하였다. 각 WSI는 일정 크기의 패치로 분할된 후 동결된 UNI 인코더를 거쳐 고차원 특징 벡터로 변환된다.

동일 환자에 복수의 WSI가 존재하므로 2단계 계층적 집계를 적용하였다. 1단계에서는 각 WSI 내 패치 피쳐 $\{h_1, \dots, h_k\}$ 에 집계 함수를 적용하여 슬라이드 수준 표현 z_s 를 생성하고, 2단계에서는 동일 환자에 속한 슬라이드 표현 $\{z_1, \dots, z_S\}$ 를 통합하여 환자 수준 표현 z_p 를 생성한다. 나이, 성별, 병기 등 9개의 임상 변수를 결합하고 이를 완전연결층에 통과시켜 위험도 점수(risk score)를 출력한다. 임상 변수의 구성과 결합 방식은 모든 비교 모델에서 동일하게 적용하였다.

환자의 생존 위험도를 예측하기 위해서는 Cox proportional hazards model의 부분우도(partial likelihood)에 기반한 손실함수를 사용하였다. 이 방법은 정확한 생존시간 자체를 직접 예측하기보다 환자 간 상대적인 위험도를 학습하며, 중도절단(censoring)된 환자는 중도절단 시점 이전까지 위험집합에 포함되므로, 관측 가능한 생존 정보를 학습에 활용할 수 있다. 모델의 생존 예측 성능은 concordance index(C-index)를 이용하여 평가하였다. C-index는 비교 가능한 환자 쌍에서 실제로 더 이른 시점에 사건이 발생한 환자에게 모델이 더 높은 위험도 점수를 부여한 비율을 나타낸다. C-index가 0.5에 가까울수록 무작위 수준의 예측을 의미하며, 1에 가까울수록 환자 간 생존 위험 순위를 정확하게 예측했음을 의미한다. 따라서 Cox partial likelihood loss는 모델 학습을 위한 목적함수로 사용되고, C-index는 학습된 모델의 순위 기반 생존 예측 성능을 평가하기 위한 지표로 사용하였다.

<표 1> 생존 예측 결과 비교

Method	Mean±Std	Min	Max
Mean Pooling	0.73±0.04	0.66	0.77
ABMIL	0.75±0.03	0.71	0.79
TransMIL	0.73±0.05	0.66	0.78
MambaMIL	0.73±0.06	0.63	0.79

4. 결과 및 토의

TCGA-BRCA 코호트의 WSI 와 임상 정보를 수집하였다. 초기 수집된 WSI 피쳐 파일은 총 1,645 개였으며, 각 환자는 평균 약 2.2 장의 WSI 를 보유하였다. 임상 정보와 매칭한 결과 총 752 명의 환자와 151 건의 사망 사건이 최종 분석에 포함되었다. 데이터 누수를 방지하기 위해 환자 단위로 데이터를 분할하고, 사건 여부를 기준으로 stratified 5-fold 교차검증을 수행하였다.

모든 모델은 Adam 옵티마이저(학습률 1×10^{-4})를 사용하여 50 에포크까지 학습하였으며, 검증 C-index 기준 조기 종료를 적용하였다. 환자 단위로 위험도 점수를 산출하고, 16 명의 환자를 하나의 미니배치로 구성하여 Cox 부분우도 손실을 계산하였다.

<표 1>과 같이 ABMIL, TransMIL, MambaMIL 은 WSI 기반 분류 과제에서 순차적인 성능 향상을 보고해왔으나, UNI 기반 생존 예측에서는 상반된 결과를 보였다. ABMIL 이 평균 C-index 0.75 ± 0.03 으로 가장 높은 성능과 가장 낮은 폴드 간 편차를 기록하였다. 반면 Mean Pooling, TransMIL, MambaMIL 은 평균 0.73 으로 유사하였으며, 특히 MambaMIL 은 최솟값 0.63, 표준편차 0.06으로 가장 큰 변동성을 보였다. 이러한 결과는 UNI의 우수한 표현력을 지닌 패치 특징으로 인해, 추가적인 패치 간 관계 모델링의 기여도가 제한되었을 가능성을 시사한다. 아울러 본 연구의 사건 수가 151 건으로 제한적인 점도 파라미터 규모가 큰 모델의 과적합을 유발했을 가능성이 있다. 복잡한 모델일수록 소수의 학습 사례에 과도하게 적합되어 폴드 간 성능 편차가 크게 나타난 점은 이러한 해석을 뒷받침한다.

5. 결론

본 연구는 UNI 기반 피쳐 추출기와 환자 단위 계층적 집계 구조를 고정한 환경에서 Mean Pooling, ABMIL, TransMIL, MambaMIL 네 가지 집계 기법의 생존예측 성능을 stratified 5-fold 교차검증으로 비교하였다. 그 결과 구조적 복잡도가 낮은 ABMIL 이 가장 높은 평균 성능과 안정성을 보여, 강력한 사전학습 특

징 환경에서는 집계 구조의 복잡성 증가가 반드시 성능 향상으로 이어지지 않을 수 있음을 확인하였다.

다만 본 연구는 단일 데이터셋(TCGA-BRCA)에 한정되며, 전체 752 명 중 사망 사건이 151 건으로 사건 발생률이 낮아 파라미터 규모가 큰 집계 구조의 학습에 불리한 조건이었을 수 있다. 향후에는 다양한 피쳐 추출기 간 비교와, 보다 풍부한 임상 정보 및 유전체·오믹스 데이터를 결합한 멀티모달 생존예측으로의 확장이 필요하다.

감사의글

This research was supported by the MSIT(Ministry of Science and ICT), Korea, under the National Program for Excellence in SW (2024-0-00071) supervised by the IITP(Institute of Information & communications Technology Planning & Evaluation).

참고문헌

- [1] R. J. Chen, T. Ding, M. Y. Lu, et al., "Towards a general-purpose foundation model for computational pathology," Nature Medicine, vol. 30, pp. 850-862, 2024.
- [2] S. Wiegrefe, P. Kopper, R. Sonabend, B. Bischl, and A. Bender, "Deep Learning for Survival Analysis: A Review," Artificial Intelligence Review, vol. 57, article 65, 2024.
- [3] G. Campanella, M. G. Hanna, L. Geneslaw, A. Mirafior, V. Werneck Krauss Silva, K. J. Busam, et al., "Clinical-grade computational pathology using weakly supervised deep learning on whole slide images," Nature Medicine, vol. 25, no. 8, pp. 1301-1309, 2019.
- [4] M. Ilse, J. Tomczak, and M. Welling, "Attention-based deep multiple instance learning," International Conference on Machine Learning (ICML), Stockholm, Sweden, 2018, pp. 2127-2136.
- [5] M. Y. Lu, D. F. K. Williamson, T. Y. Chen, et al., "Data-efficient and weakly supervised computational pathology on whole-slide images," Nature Biomedical Engineering, vol. 5, pp. 555-570, 2021.
- [6] Z. Shao, H. Bian, Y. Chen, Y. Wang, J. Zhang, and X. Ji, "TransMIL: Transformer based correlated multiple instance learning for whole slide image classification," Advances in Neural Information Processing Systems (NeurIPS), Online, 2021, pp. 2136-2147.
- [7] S. Yang, Y. Wang, and H. Chen, "MambaMIL: Enhancing long sequence modeling with sequence reordering in computational pathology," International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI), Marrakesh, Morocco, 2024, pp. 296-306.