

WSI 생존예측을 위한 MIL 집계 기법 비교

김유진

승실대학교 소속

e-mail : yuzeeny1116@naver.com

Comparison of MIL Aggregation Methods for WSI-based Survival Prediction

Yujin Kim

Soongsil University

Abstract

In digital pathology, various Multiple Instance Learning (MIL) aggregation methods have been proposed for survival prediction from Whole Slide Images (WSIs). These methods have evolved toward increasing complexity, beginning with simple mean pooling and progressing to attention-based approaches that learn the importance of individual instances, as well as Transformer- and State Space Model-based approaches that model inter-instance correlations. However, such complex aggregation structures entail high computational cost and implementation complexity, and it remains insufficiently verified whether this complexity is still warranted in recent settings where powerful pretrained feature extractors are widely used. To address this, we compare Mean Pooling, ABMIL, TransMIL, and MambaMIL under an identical feature extraction setting to analyze the relationship between aggregation complexity and survival prediction performance. Experimental results reveal performance differences across aggregation methods, with the relatively simple ABMIL achieving the highest C-index. This suggests that when powerful pretrained features

are used, increased aggregation complexity does not necessarily lead to improved performance.

I. 서론

병리 이미지(Whole Slide Image, WSI)는 조직 슬라이드를 초고해상도로 디지털화한 영상으로, 세포 구조와 종양 미세환경 등의 정보를 담고 있어 암 진단과 예후 예측 등 다양한 의료 분야에 활용된다. 디지털 병리의 발전과 함께 WSI 기반 인공지능 연구가 지속적으로 발전해 왔으며 [1,2], 파운데이션 모델의 도입으로 표현력이 크게 향상되었다 [3,4,5]. 이러한 표현 학습의 발전은 특히 환자의 생존 기간 및 예후를 예측하는 생존분석에서 두드러지며 환자 별 치료 전략과 추적 관찰 계획 수립에 중요한 근거를 제공한다 [6].

그러나 WSI는 일반적인 의료영상에 비해 매우 큰 해상도를 가지므로 전체 영상을 직접 입력으로 활용하기 어렵다. 이를 해결하기 위해 WSI를 작은 패치 단위로 분할하여 특징을 추출한 뒤 이를 통합하여 환자 수준의 표현을 생성하는 다중 인스턴스 학습(Multiple Instance Learning, MIL) 기반 접근법이 널리 사용된다 [7]. 이러한 MIL 집계 기법은 패치 간 중요도와 상호작용을 모델링하는 방향으로 점차 발전해 왔다 [8-11].

기존 연구는 주로 복잡한 MIL 구조의 개발에

집중해 왔으나, 파운데이션 모델로 고품질 특징을 확보할 수 있는 환경에서도 복잡한 집계 구조가 반드시 필요한지는 충분히 검증되지 않았다. 본 연구에서 집계 구조의 복잡성이란 연산량이 아니라, 인스턴스 간 상호작용을 모델링하는 구조적 정교함을 의미한다. 따라서 본 연구에서는 네 가지의 MIL 집계 기법의 생존예측 성능을 비교하여, 강력한 사전학습 특징 환경에서 집계 구조의 복잡성이 성능 향상에 기여하는지를 검토한다.

II. 본론

2.1 다중 인스턴스 학습

MIL은 인스턴스 단위의 레이블 없이 bag 단위의 레이블만을 이용하는 약지도 학습이다. WSI 분석에서는 다수의 패치(인스턴스)를 슬라이드 또는 환자 수준의 표현(bag)으로 집계하는 함수가 모델 성능을 결정하는 핵심 요소이다. 집계 방식의 선택은 패치 간 관계를 어떻게 표현할지를 결정하며, 하위 태스크의 성능에 직접적인 영향을 미친다.

2.2 MIL 집계 기법

기본적인 방식인 Mean Pooling은 패치 간 중요도 차이와 상호작용을 고려하지 못한다. MIL 집계 기법들은 이러한 한계를 보완하고자 발전해 왔다.

Ilse et al.[8]은 각 패치에 학습 가능한 가중치를 부여하는 ABMIL을 제안하였다. 패치 피쳐 h_k 에 대한 게이트 어텐션 점수는 식 (1)과 같이 산출되며, 이를 가중합하여 슬라이드 수준 표현을 생성하면 식 (2)와 같다.

$$a_{k,m} = \frac{\exp W_{a,m}(\tanh(V_a h_k^T) \odot \text{sigm}(U_a h_k^T))}{\sum_{j=1}^N \exp W_{a,m}(\tanh(V_a h_j^T) \odot \text{sigm}(U_a h_j^T))} \quad (1)$$

$$h_{slide,m} = \sum_{k=1}^N a_{k,m} h_k \quad (2)$$

게이트 어텐션은 $\tanh$ 와 시그모이드의 요소별 곱을 통해 어텐션 점수의 비선형 표현력을 강화한다. 여기서 각 패치의 가중치는 해당 패치의 피쳐만으로 독립적으로 산출되며, 다른 패치를 참조하지 않는다. 즉 이 방식의 어텐션은 패치 간 상호작용을 계산하는 Transformer의 self-attention과 달리, 학습된 중요도에 기반한 가중 평균에 해당하며 패치 간 관계는 모델링하지 못한다. 본 연구에서는 Lu et

al.[9]의 CLAM에서 인스턴스 단위 군집화 손실을 제외한 Gated Attention Pooling 모듈만을 집계기로 활용하였다.

Shao et al.[10]은 self-attention으로 패치간 상관관계를 표현할 수 있는 TransMIL을 제안하였다. 표준 self-attention의 $O(N^2)$ 복잡도는 수만 개의 패치로 구성된 WSI에 적용하기 어려우므로, 이를 Nyström 근사를 통해 선형 복잡도로 완화하였다. 그리고 패치의 2차원 공간 위치 정보를 함께 인코딩하여 공간적 상관관계를 포착했다.

Yang et al.[11]은 TransMIL과 마찬가지로 패치 간 의존성을 모델링하되, 이를 self-attention이 아닌 선택적 상태공간모델 (Selective State Space Model, SSM)로 처리하는 MambaMIL을 제안하였다. SSM은 패치 시퀀스를 순차적으로 처리하여 장거리 의존성을 $O(N)$ 복잡도로 모델링한다. 그러나 이러한 순차적 처리 방식은 입력 순서에 따라 결과가 변형되는 한계가 존재한다. 이에 MambaMIL은 패치를 공간 좌표 기반으로 재배열하여 지역적 연속성을 확보하는 순서화 전략을 통해 해결하였다.

	Trainable Parameters
Mean Pooling	788,578 (0.79 M)
ABMIL	1,051,491 (1.05 M)
TransMIL	2,935,411 (2.94 M)
MambaMIL	4,753,251 (4.75 M)

표 1. 집계 기법별 전체 모델의 학습 가능한 파라미터 수

각 집계 기법을 적용한 모델의 표 1과 같이, 인스턴스 간 상호작용을 모델링하는 TransMIL과 MambaMIL이 더 많은 파라미터를 필요로 했다.

III. 구현

3.1 전체 파이프라인

본 연구의 파이프라인은 UNI 기반 특징 추출, 계층적 MIL 집계 및 Cox 회귀 기반 생존 예측으로 구성된다. 성능 비교를 위해 특징 추출기와 후속 구조는 고정하고 1단계 집계 기법만을 교체하여 실험을 진행하였다. 패치 수준의 특징 추출에는




그림 1. 제안하는 계층적 MIL 집계 기반 생존예측
파이프라인의 전체 구조

대규모 병리 영상 데이터로 사전 학습된 파운데이션 모델인 UNI[1]를 활용하였다. 각 WSI는 일정 크기의 패치로 분할된 후 동결된 UNI 인코더를 거쳐 고차원 특징 벡터로 변환된다.

동일 환자에 복수의 WSI가 존재하므로 2단계 계층적 집계를 적용하였다. 1단계에서는 각 WSI 내 패치 피처 $\{h_1, \dots, h_k\}$ 에 집계 함수를 적용하여 슬라이드 수준 표현 z_s 를 생성하고, 2단계에서는 동일 환자에 속한 슬라이드 표현 $\{z_1, \dots, z_S\}$ 를 통합하여 환자 수준 표현 z_p 를 생성한다.

환자 수준 표현 z_p 에 임상 데이터 벡터 c 를 연접하여 최종 입력 표현을 구성하고, 완전연결층을 통해 위험도 점수(risk score) $\hat{r}$ 를 출력한다.

$$\hat{r} = f_{\theta}([z_p || c]) \quad (3)$$

생존예측 학습에는 Cox 비례위험모형에 기반한 부분 로그 가능도 손실을 사용한다.

$$L = -\sum_i \delta_i (\hat{r}_i - \log \sum_{j \in R(t_i)} \exp(\hat{r}_j)) \quad (4)$$

여기서 δ_i 는 사건 발생 여부(1: 사망, 0: 중도절단), $R(t_i)$ 는 시점 t_i 에서의 위험 집합(risk set)을 나타낸다. 모델의 평가 지표로는 중도절단 데이터를 처리할 수 있는 C-index(Concordance Index)를 사용한다.

3.2 데이터셋 및 실험 설정

TCGA-BRCA 코호트의 WSI와 임상 정보를 수집하였다. 초기 수집된 WSI 피처 파일은 총 1,645개였으며, 각 환자는 평균 약 2.2장의 WSI를 보유하였다. 임상 정보와 매칭한 결과 총 752명의 환자와 151건의 사망 사건이 최종 분석에 포함되었다. 데이터 누수를 방지하기 위해 환자 단위로 데이터를

분할하고, 사건 여부를 기준으로 stratified 5-fold 교차검증을 수행하였다. 평가지표는 C-index를 사용하였다.

모든 모델은 Adam 옵티마이저(학습률 1×10^{-4})를 사용하여 50 에포크까지 학습하였으며, 검증 C-index 기준 조기 종료를 적용하였다. 한 번에 슬라이드 하나씩 처리하되, 16개 슬라이드의 위험도 점수를 누적하여 Cox 부분우도 손실을 계산하였다.

3.3 실험 결과 및 분석

	Mean $\pm$ Std	Min	Max
Mean Pooling	0.73 $\pm$ 0.04	0.66	0.77
ABMIL	0.75 $\pm$ 0.03	0.71	0.79
TransMIL	0.73 $\pm$ 0.05	0.66	0.78
MambaMIL	0.73 $\pm$ 0.06	0.63	0.79

표 2. 생존 예측 결과 비교

ABMIL, TransMIL, MambaMIL은 WSI 기반 분류 과제에서 순차적인 성능 향상을 보고해왔으나, UNI 기반 생존 예측에서는 상반된 결과를 보였다. ABMIL이 평균 C-index 0.75 $\pm$ 0.03으로 가장 높은 성능과 가장 낮은 폴드 간 편차를 기록하였다. 반면 Mean Pooling, TransMIL, MambaMIL은 평균 0.73으로 유사하였으며, 특히 MambaMIL은 최솟값 0.63, 표준편차 0.06으로 가장 큰 변동성을 보였다. 이러한 결과는 UNI의 우수한 표현력을 지닌 패치 특징으로 인해, 추가적인 패치 간 관계 모델링의 기여도가 제한되었기 때문으로 해석된다. 아울러 본 연구의 사건 수가 151건으로 제한적인 점도 파라미터 규모가 큰 모델의 과적합을 유발했을 가능성이 있다.

복잡한 모델일수록 소수의 학습 사례에 과도하게 적합되어 폴드 간 성능 편차가 크게 나타난 점은 이러한 해석을 뒷받침한다.

IV. 결론 및 향후 연구 방향

본 연구는 UNI 기반 피쳐 추출기와 환자 단위 계층적 집계 구조를 고정한 환경에서 Mean Pooling, ABMIL, TransMIL, MambaMIL 네 가지 집계 기법의 생존예측 성능을 stratified 5-fold 교차검증으로 비교하였다. 그 결과 구조적 복잡도가 낮은 ABMIL이 가장 높은 평균 성능과 안정성을 보여, 강력한 사전학습 특징 환경에서는 집계 구조의 복잡성 증가가 반드시 성능 향상으로 이어지지 않음을 확인하였다.

다만 본 연구는 단일 데이터셋(TCGA-BRCA)에 한정되며, 전체 752명 중 사망 사건이 151건으로 사건 발생률이 낮아 파라미터 규모가 큰 집계 구조의 학습에 불리한 조건이었을 수 있다. 또한 단일 피쳐 추출기(UNI)에 기반하였다는 점에서 결과의 일반화에는 한계가 있다. 따라서 향후에는 다양한 피쳐 추출기 간 비교와, 임상 정보 및 유전체·오믹스 데이터를 결합한 멀티모달 생존예측으로의 확장이 필요하다.

참고문헌

- [1] N. Dimitriou, O. Arandjelović, and P. D. Caie, "Deep learning for whole slide image analysis: An overview," *Front. Med.*, vol. 6, art. 264, 2019.
- [2] X. Li *et al.*, "A comprehensive review of computer-aided whole-slide image analysis: From datasets to feature extraction, segmentation, classification and detection approaches," *Artif. Intell. Rev.*, vol. 55, no. 6, pp. 4809-4878, 2022.
- [3] R. J. Chen *et al.*, "Towards a general-purpose foundation model for computational pathology," *Nat. Med.*, vol. 30, pp. 850-862, 2024.
- [4] E. Vorontsov *et al.*, "A foundation model for clinical-grade computational pathology and rare cancers detection," *Nat. Med.*, vol. 30, pp. 2924-2935, 2024.
- [5] D. Nechaev, A. Pchelnikov, and E. Ivanova, "Hibou: A family of foundational vision transformers for pathology," *arXiv:2406.05074*, 2024.
- [6] Z. Wang *et al.*, "Enhancing WSI-based survival analysis with report-auxiliary self-distillation," in *Proc. Med. Image Comput. Comput.-Assist. Interv. (MICCAI)*, 2025, pp. 197-207.
- [7] G. Campanella *et al.*, "Clinical-grade computational pathology using weakly supervised deep learning on whole slide images," *Nat. Med.*, vol. 25, no. 8, pp. 1301-1309, 2019.
- [8] M. Ilse, J. Tomczak, and M. Welling, "Attention-based deep multiple instance learning," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2018, pp. 2127-2136.
- [9] M. Y. Lu *et al.*, "Data-efficient and weakly supervised computational pathology on whole-slide images," *Nat. Biomed. Eng.*, vol. 5, pp. 555-570, 2021.
- [10] Z. Shao *et al.*, "TransMIL: Transformer based correlated multiple instance learning for whole slide image classification," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 34, 2021, pp. 2136-2147.
- [11] S. Yang, Y. Wang, and H. Chen, "MambaMIL: Enhancing long sequence modeling with sequence reordering in computational pathology," in *Proc. Med. Image Comput. Comput.-Assist. Interv. (MICCAI)*, 2024, pp. 296-306.